

宁波诺丁汉大学
2026 年数学建模校内选拔赛
参赛论文

题目名称	股票指数投资组合交易策略优化问题
题目选择	B 题
队长姓名	曹佳宝
队长学号	20809598
队员 2 姓名	蒋圣钦
队员 2 学号	20809605
队员 3 姓名	何思南
队员 3 学号	20810044
所属学院/专业	理工学院 计算机科学与技术
队长电话	17816637615
提交日期	2026 年 4 月 24 日

摘要

本研究旨在构建量化交易策略模型，通过在标普 100 指数（SP100）与恒生指数（HSI）之间动态配置仓位，实现投资收益的最大化。在方法上，团队首先对各指数数据进行主成分分析（PCA）以实现降维，随后采用岭回归（Ridge Regression）构建预测模型，并通过对数据集进行合理划分，在验证集上完成参数调优，最终在测试集上评估模型效果。交易执行方面，研究设计了一种基于预测模型的因子动量择时进攻模型（FMTM），通过模型预测信号动态调整仓位，并进行相应的风险控制。基于三次分段回测的结果，该策略的收益均显著优于全仓买入持有及分别半仓策略。在表现最优的一次回测中，仅 48 个交易日，账户总资产即由 100,000 美元增长至 134,090.4 美元，相较于基准策略平均额外提升约 10,000 美元的收益，充分验证了所构建预测模型与交易策略的有效性及优越性。

关键词：PCA；指数交易模型；Ridge；动量参与全仓交易

一、问题重述

股票指数是反映特定股票市场整体表现的核心指标，由各成分股加权计算得出。标普 100 指数（以下简称 SP100）与恒生指数（以下简称 HSI）分别是美国、香港股市的重要指数，其成分股在行业分布、波动特征及风险收益结构上均存在显著差异。本研究的核心目标是：基于历史收益率数据，构建一个风险可控且收益最大化的投资组合交易策略。

本次交易策略模型研究以 2023-11-01 为投资起点，初始资金为 100,000 美元，投资方案仅在 SP100 指数与 HSI 指数之间进行合理配置。数据涵盖 2023 年 11 月 1 日至 2024 年 10 月 11 日共计 248 个交易日，包含 SP100 指数 101 只成分股与 HSI 指数 83 只成分股的每日相对收益率。其中包含 SP100 指数 101 只成分股、HSI 指数 83 只成分股的每日相对收益率，共计 248 条交易日记录。交易时，每笔交易需支付对应佣金（SP100 佣金率 0.1%，HSI 佣金率 0.15%），按年化 0.05% 每日计提管理费，采用当日收盘价成交，最小交易单位为 1 美元，不允许卖空，交易决策可基于截至当日的历史信息。

基于上述背景和数据，本次研究围绕以下三个核心问题展开建模与求解：

1. 指数成分股收益率特征分析

- 基于提供的历史相对收益率数据，计算两种指数各成分股的日均收益率、年化收益率、年化波动率、夏普比率等关键统计指标，识别表现最优与最差的成分股
- 分析指数成分股收益率相关性，找出高相关与低相关的成分股组合
- 通过聚类分析，划分出具有相似收益率特征的成分股群组

2. 指数整体走势分析与预测

- 需明确指数整体收益率的计算方法，基于成分股相对收益率数据构造

两种指数的日收益率序列

- b) 选择合适的预测方法建立两种指数收益率的短期预测模型
 - c) 采用滚动窗口方式进行预测，明确初始训练窗口长度、滑动步长及样本外区间起始点，给出预测精度指标，并绘制预测曲线与实际值的对比图
3. 最优指数配置交易策略设计
- a) 需建立数学优化模型，以投资期末投资组合总价值最大化为目标，充分考虑交易成本、最小交易单位、不允许卖空、现金持有限制、信息时效性等约束条件
 - b) 明确交易决策的生成机制，可基于前一问题的预测结果或技术指标制定决策规则
 - c) 利用历史数据对策略进行完整回测，计算投资期末的最终价值，绘制投资组合净值曲线与资产配置变化图
 - d) 设计至少三种基准策略，对比分析此次研究策略的收益表现，验证其有效性与优越性

二、问题分析

2.1 指数成分股收益率特征分析

1. **统计指标计算与成分股评价：**附件提供了日相对收益率数据。首先需将相对收益率转换为对数收益率或直接使用简单收益率，进而计算各成分股在观察期内的日均收益率、年化收益率（简单年化）、年化波动率（以日波动率乘以交易日数平方根计算）以及夏普比率（假设无风险利率为 0 或给定常数）。通过比较这些指标，可直观筛选出高收益低波动（表现好）与低收益高波动（表现差）的个股，为后续构建增强型指数或回避劣质股提供依据。
2. **成分股间相关性分析：**需分别计算 SP100 内部 101 只成分股之间、HSI 内部 83 只成分股之间，以及跨指数成分股之间的相关系数矩阵。通过热力图可视化并统计阈值筛选，识别高相关组和低相关组。低相关组合是分散非系统性风险的关键，这一发现可为问题三的资产配置提供对冲思路。
3. **聚类分析：**基于收益率序列特征（如日均收益率、波动率、偏度、峰度或直接基于收益率时间序列的相关系数距离），可采用 K-Means 或层次聚类算法对成分股进行分组。可以利用将具有相似风险收益特征的股票归类，进而归纳两种指数的主导风格（例如成长型、价值型、高波动型等），从而在宏观上把握指数特性。

2.2 指数整体走势分析与预测

1. 我们通过分析，明确整体收益率的计算方式为对每个成分股进行平均加权的计算，进而得出指数的整体收益率。对于日收益率序列，我们可以通过将相对收益率-1 来得到简单收益率。结合时间构建出日收益率序列

2. 建立短期预测模型面临两个挑战：一是维度高（每个指数包含 80 只以上成分股），二是样本量有限（仅 248 个交易日）。在此条件下，复杂的机器学习模型极易过拟合或学习到噪声，无法有效预测指数未来走势。[1]因此，本研究选用逻辑回归配合 Ridge 回归作为预测模型，两者适合处理具有共线性的股票数据，且不易过拟合。我们采用逻辑回归配合 Ridge 回归来进行预测，由于简单的逻辑回归配合 Ridge 模型适合学习股票的共线性，同时也不容易学习到噪声。为应对高维问题，采用 PCA 对数据进行降维，在防止过拟合的同时提升计算效率。
3. 根据题目要求，需明确初始训练窗口、滑动步长及样本外区间起始点。为了符合指数类金融产品的特性，我们预测模型的评估指标采用皮尔逊系数，用于表述预测模型和真实情况的线性相关性。同时通过直观对比预测曲线与实际值，检验模型对趋势拐点的捕捉能力。

2.3 最优指数配置交易策略设计

为了满足题目需求，我们有两种方式来进行交易模型的建立。一种方案是基于历史数据的技术分析直接生成资产分配决策；另一种方案是依托问题二中建立的预测模型，利用预测信号指导仓位调整。若采用技术分析手段，可利用成分股的协方差矩阵，结合多资产凯利公式直接求解最优仓位配比。若依托于预测模型且模型足够准确，可采用全仓进攻辅以风险控制策略，在最大化收益的同时降低回撤风险。

我们采用以下三种基准策略：

1. 全仓 SP100 指数
2. 全仓 HSI 指数
3. 半仓 SP100 指数，半仓 HSI 指数

最终，通过完整回测将本策略与基准策略的期末总资产进行对比，以验证决策模型的有效性与优越性。

三、模型假设

我们建立的模型基于以下假设：

1. 模型生成的交易信号会被自动执行，不存在人为干预。
依据：自动化执行能够消除情绪波动等人为非理性因素对交易决策的干扰，使策略表现更加稳定[2]。
局限性：可能使模型在市场极端事件面前缺乏灵活应对能力。
2. 投资组合中持有的现金部分不产生利息收入，也不因通胀而贬值。
依据：根据题目规则，使得交易没有现实中那么复杂，整个交易的环境变量大大减小。
局限性：与现实并不完全相符，无法直接运用于现实中的指数交易。

3. 本研究中的交易行为不会对市场价格产生冲击（因资金量相对于市场整体交易额极小）。

依据：初始资金为 100,000 美元，而 SP100 与 HSI 成分股日均总成交额通常在 5,000 万美元以上，本策略的资金规模远不足以对市场价格产生可观测的冲击。[3]

局限性：可能低估极端流动性枯竭场景下的滑点成本。

4. 题目规定年化管理费率为 0.05%，每日计提管理费比例为 0.05% / 252。管理费仅在交易日从持仓净值中扣除，非交易日不计提。

依据：按国际金融市场惯例，一年约含 252 个交易日。

局限性：每年为 365 天，每年的总交易日不确定。

5. 假设无风险利率为 0%，不考虑国债收益率的大小对之的影响。

依据：题目没有给出相关信息，设置为 0 有利于简化交易环境。

局限性：不符合真实的市场交易，无法将模型直接运用于现实交易。

四、符号说明

符号	含义说明	单位/备注
N	成分股数量	个
T	交易日数量	天
$r_{t,i}$	第 t 天第 i 只股票收益率	无量纲
R	收益率矩阵	无量纲
X	标准化后的收益矩阵	无量纲
Σ	协方差矩阵	无量纲，规模由训练数据决定
λ_i	第 i 个特征值	无量纲
v_i	第 i 个特征向量	无量纲
k	主成分个数	个
Z	降维后的因子矩阵	无量纲
y_t	第 t 天预测目标(未来收益)	百分比，无量纲
w	回归系数	参数，无量纲
α	正则化参数	参数，无量纲

符号	含义说明	单位/备注
x_t	投资于 SP100 的金额	\$(美元)，最小单位为 1 美元
y_t	投资于 HSI 的金额	\$(美元)，最小单位为 1 美元
$cash_t$	当前现金	\$(美元)，最小单位为 1 美元
w_t	资产权重	无量纲
s_t	综合进攻信号	无量纲
M_t	动量指标	无量纲
m	管理费	百分比，无量纲
sp	对标普 100 指数的佣金率	百分比，无量纲
hsi	对恒生指数的佣金率	百分比，无量纲
K_1	K-means 聚类数	个
K_2	层次聚类簇数	个
$Similarity$	余弦相似度	无量纲
l	年化收益率	百分比，无量纲
q	年化波动率	百分比，无量纲
$sharpe$	夏普比率	百分比，无量纲
R_f	无风险利率	百分比，无量纲

五、模型建立与求解

5.1 问题一

5.1.1 数据预处理与指标计算

附件 1 与附件 2 分别提供了 SP100 指数 101 只成分股与 HSI 指数 83 只成分股自 2023 年 11 月 1 日至 2024 年 10 月 11 日的每日相对收益率数据。我们将相对收益率定义为当日收盘价与前一日收盘价的比值，随后将相对收益率-1 来得到简单收益率。

对于日均收益率，我们通过累和进行计算：

$$R_t = \frac{1}{N} \sum_{i=1}^N r_{t,i}$$

对于年化收益率，我们代入公式：

$$l = R_t \times T$$

对于年化波动率，我们用如下公式计算：

$$q = \sqrt{\frac{T_{\text{交易}}}{T_{\text{总天数}}} \cdot \sum_{i=1}^N (R_t - r_{i,t})^2}$$

对于夏普比率，我们用如下公式计算：

$$sharpe = \frac{l - R_f}{q}$$

最终得出题目所要求的所有统计学指标。

5.1.2 成分股收益率相关性分析

为了探究资产间的联动关系，我们采用标准化处理后的余弦相似度来评估成分股收益序列的趋势一致性。

$$\text{similarity} = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

我们设置了高相关阈值 ≥ 0.9 与低相关阈值 ≤ -0.7 ，通过构建相关性热力图直观展示成分股组合的相关程度。余弦相似度相较于皮尔逊相关系数，更侧重于收益变化方向的一致性。高相似度组合通常受相同宏观因子驱动，低相似度组合则具备更好的对冲潜力，为资产配置提供了分散化的依据。

5.1.3 成分股聚类分析

为了保证对成分股分群的客观性与稳健性，此次研究采用了交叉验证策略，同时运用 K-Means 与凝聚层次聚类两种算法对股票特征进行挖掘。




图 5-1 肘部法则图




图 5-2 轮廓系数图

我们对两种模型分别进行了超参数寻优。对于 K-Means，我们利用肘部法则（如图 5-1 所示）观察误差平方和的下降趋势，确定了最佳聚类数 $K_1=10$ ；对于凝聚层次聚类，利用轮廓系数（如图 5-2 所示）评估不同 K_1 值下的聚类质量，结果显示当 $K_2=9$ 时（ K 值过低或者过高对于模型分析无实际意义，需要舍去）模型达到最优性能。

K-Means 基于质心距离最小化划分样本，层次聚类则基于样本间的连接关系逐

层合并，两种算法原理不同。当我们通过不同的评价标准（SSE 肘部与轮廓系数最大化）在两个独立模型中均得出相近的类别数时，这一高度一致性有效消除了单一算法可能带来的过拟合或偏差，有力地验证了当前聚类结果的逻辑合理性与数据内在结构的稳定性。




图 5-3 K-Means 聚类散点图




图 5-4 凝聚层次聚类散点图

接着我们分析了聚类结果 PCA 降维可视化点云图（如图 5-3），发现 K-Means 并没有很好地处理稀疏数据，并且其中出现的不规则簇更适合使用凝聚层次聚类（如图 5-4），所以最终我们选择使用凝聚层次聚类分析相似成分股群，并将聚类结果保存为 `stock_static_cluster_agglomerative.csv`（附件）。

这种基于双重算法的聚类结果，不仅在统计上具备可靠性，也为后续针对不同股票群组构建差异化投资策略提供了科学依据。

5.2 问题二

5.2.1 日收益率序列计算

指数的整体收益率是衡量市场走势的核心指标。为了消除单个成分股异常波动对指数走势的干扰，我们采用横截面平均法构造指数的日收益率序列。

对于包含 N 个成分股的指数，假设第 t 日第 i 只成分股的收益率为 $R_{i,t}$ ，则指数的当日收益率 R 计算公式为：

$$R_t = \frac{1}{N} \sum_{i=1}^N r_{i,t}$$

具体实施时，首先将相对收益率减去 1 转换为简单收益率，随后按行取均值（即对每个交易日所有成分股收益率求算术平均），得到指数的日收益率序列，获取该交易日的平均收益率。通过该方法计算出的序列，能够反映指数整体的收益特征。

5.2.2 建立短期预测模型

考虑到金融时间序列数据存在多重共线性和高噪声特征，我们构建了一个基于多因子特征工程与 Ridge 岭回归的监督学习预测模型。

1. 目标变量构建：预测目标为下个交易日的相对收益率。

$$P_{target} = P_{n+1}$$

2. 特征工程：为了提高模型的预测能力，我们构建了多维特征

我们利用 PCA 将原始收益率数据降维。在选取最佳维数超参数方面，我们使用了方差解释率曲线[4]，通过寻找解释率拐点确定最优主成分数 $N=5$ ，在保留市场核心特征的情况下减少特征维度，降低过拟合风险。（如图 5-5）




图 5-5 PCA 方差解释率曲线

在 PCA 降维的流程中，对于每个指数，我们先构建原始收益矩阵（代码中表现为 returns）

$$r \in R^{T \times N}$$

矩阵的第 t 行为第 t 天所有股票收益向量。

随后，为了防止数据泄露，我们只在训练集 train 进行数据的处理。

我们先对 r 中每一支股票进行均值和标准差的计算：

$$\mu_j = \frac{1}{T_{train}} \times \sum_{t \in train} R_{t,j}$$

$$\sigma_j = \sqrt{\frac{1}{T_{train}} \times \sum_{t \in train} (R_{t,j} - \mu_j)^2}$$

随后，进行标准化操作：

$$X_{t,j} = \frac{r_{t,j} - \mu_j}{\sigma_j}$$

得到标准化数据之后，我们接着着手对其进行协方差矩阵的构建：

$$\Sigma = \frac{1}{T_{train} - 1} X_{train}^T X_{train}$$

构建完协方差矩阵之后，对其进行特征分解：

$$\Sigma v_i = \lambda_i v_i, \lambda_1 \geq \lambda_2 \geq \dots$$

对于分解出的所有特征，选取前 k 个主成分方向构建向量：

$$V_k = [v_1, \dots, v_k] \in R^{N \times k}$$

最后，设置 x_t 为在时间 t 的标准化向量， X 为 x_t 组成的向量，构建主成分因子矩阵

$$Z = X \cdot V_k \in R^k$$

由此，我们成功使用 PCA 压缩了数据的维度，有效防止了过拟合和噪点污染模型的情况。在 PCA 降维基础上，进一步构造各因子的多窗口移动平均（5、10、20、40 日）作为动量特征，以及滚动标准差（5、20 日）作为波动率特征，共同构成模型输入。

在预测算法方面，模型采用岭回归算法，其目标函数通过在线性回归最小二乘法中引入 L2 正则化项，防止过拟合：

$$\min_w \|Xw - y\|_2^2 + \alpha \|w\|_2^2$$

其中，超参数 α 通过在预设集合 $\{0.01, 0.1, 1.0, 10.0, 100.0\}$ 中进行网格搜索与交叉验证，选择最优参数进行训练。

5.2.3 样本外预测评估

我们将整体一年的样本按比例分成三个部分：

1. 训练集：50%
2. 验证集：25%
3. 测试集：25%

我们通过用训练集训练模型，用验证集来进行超参数的微调和预测模型效果的初步验证。最后，我们通过在测试集上进行只有一次的效果验证来证明模型是否是真的完备。

验证结果表明，模型在样本外预测中表现良好。在 SP100 指数上仅出现 3 次方向误判，其中两次为轻微偏差并迅速修正；在 HSI 指数上也仅有少数轻微失误。

对于预测的效果，我们采用皮尔逊相关系数来衡量预测和实际的线性相关程度。两个指数的预测效果如下表所示：

HSI Pearson r	0.7196205969107505
SP100 Pearson r	0.813217657101419

表 5-1 指数对应皮尔逊系数

同时，预测的效果和实际的效果的折现对比图如下所示：




图 5-6 SP100 预测值与实际值对比图




图 5-7 HSI 预测值与实际值对比图

由结果可知，模型对 HSI 与 SP100 的预测值与实际值的皮尔逊相关系数均高于 0.7，表明预测模型能够有效捕捉指数收益率的线性趋势，具有良好的可靠性与有效性。

但是，根据折线统计图来看（如图 5-6 和图 5-7 所示），从预测对比折线图亦可观察到，模型虽能较为准确地捕捉涨跌方向，但对涨跌幅度的预测误差相对较大。这一偏差很可能源于训练数据量有限（仅约 100 个交易日），限制了模型对收益率幅度的精确拟合能力。

5.3 问题三

5.3.1 建立数学优化模型

根据要求，我们建立了如下的数学模型：

1. 决策变量：每天的成交金额和分配，现有总资产为 cash，当天成交至 SP100 的金额为 x ，当天成交至 HSI 指数的金额为 y 。
2. 目标函数：最后一天总资产 cash 最大
3. 约束条件：

a) 单次的 $x + y < \text{cash}$

b) 每天对所有买入的资金 x 和 y 需要收取管理费。

$$x_{n+1} = x_n \times (1 - m), \quad y_{n+1} = y_n \times (1 - m)$$

c) 每笔交易都需要收取佣金。

$$x_{\text{real}} = x_{\text{input}} \times (1 - \text{sp}), \quad y_{\text{real}} = y_{\text{input}} \times (1 - \text{hsi})$$

d) 不允许做空。

$$x > 0, y > 0$$

4. 变量类型与符号：

a) x : 正整数

b) y : 正整数

c) $0 < m < 1$

d) $0 < h < 1$

e) $0 < s < 1$

5.3.2 交易决策的生成机制分析

本策略的决策过程主要依赖于预测模型的输出。首先，读取模型对当日当前指数简单收益率的预测结果：

$$y_t = \text{当日模型预测简单收益率}$$

随后，读取前三天的指数走势，并相加后乘以权重（由自行调参得出最优值）作为动量：

$$M_t = (R_1 + R_2 + R_3) \times \text{weight}$$

最后，将预测结果和动量相加，得到当日模型增长潜力：

$$S = y_t + m_t$$

关于如何在两个指数之间调整仓位，鉴于现有机制下指数趋势预测具有较高的整体准确性，本文采用了一种激进的仓位调整方法：通过比较两个目标指数的上涨潜力，选择潜力较高者进行全仓买入。在全仓持有的条件下，结合较为可靠的预

测，能够获得显著的超额收益。

$$(w_{sp}, w_{hs}) = \begin{cases} (1,0), & s_{sp} > s_{hsi} \\ (0,1), & s_{sp} < s_{hsi} \end{cases}$$

为控制风险，当模型预测结果为负收益时，策略将完全空仓，以避免潜在亏损并降低持仓期间的管理费用。在此风险控制机制下，策略可有效规避大幅度回撤。

在确定全仓买入的目标指数后，并不立即执行交易，而是进一步实施风险控制。定义每个资产的权重为：


$$\text{指数资产权重} = \frac{\text{该资产的持仓价值}}{\text{总投资组合价值}}$$

每次决策后，计算当前资产权重与上一期最新资产权重之差的绝对值。仅当该绝对值超过预设阈值（当前模型为 0.15）时，模型才执行调仓交易；否则维持原有仓位不变。该机制旨在防止因预测偏差导致的错误交易损失，同时降低交易佣金成本，更有效地保留现有资金。

5.3.3 决策模型完整回测与结果呈现

我们分别选取了 0-150 天，150-200 天和 200 天到 248 天进行三段完整回测，从而增强模型的说服力。针对每一段时间，我们将前 50 天作为训练集，中间 50 天作为验证集，剩下的时间作为测试集，进而用决策模型来进行训练，决策和调控。在这些数据集中，训练集和验证集共同用于训练模型，在这段时间并不交易，只有在测试集模型才开始进行决策。

在这三段测试中，模型的表现分别如下（如图 5-8， 5-9， 5-10 所示）：






图 5-8 回测一：净值曲线对比与资产配置变化图

Test 2





图 5-9 回测二：净值曲线对比与资产配置变化图

Test 3







图 5-10 回测三：净值曲线对比与资产配置变化图

三次回测的期末净值对比如下表所示：



具体的数值如下：

	FMTM 决策模型	全仓 SP100	全仓 HSI 指数	半仓 SP100 半仓 HSI
0-150	110248.2	98708.3	104175.2	101441.8
150-200	103877.1	102185.3	89902.5	96043.9
200-248	134090.4	109191.1	118908.4	114049.8

表 5-2 回测结果对比

就数据结果（如表 5-2）来看，FMTM 决策模型在三段完整回测中的表现都明显优于其他三个基准策略。如 Test3 中所示，最好的一次回测中模型可以在 48 天达到约 30%的收益，效果良好。同时，在三段回测中模型都没有出现亏损的情况，并且表现都相对优越，说明了模型的稳定性和可移植性。

从净值曲线来看，策略的净值走势基本稳定在最优全仓指数基准之上，能够有效捕捉强势指数的上涨行情，同时规避部分下跌风险。这表明预测信号对指数涨跌的判断是有效的，策略调仓逻辑合理。

从资产配置变化图上看，全仓模型能够有效的察觉更优的指数，并直接全仓进

入，可以有效地最大化收益，对于指数亏损的情况，模型也可以及时的退出，保证资产不会缩水。个别时段的决策偏差，更多源于预测模型的信号误差，而非策略框架本身的缺陷。

六、结果分析与检验

我们构建的预测模型用 PCA 进行降维，进而防止模型学到过多噪声。同时将 PCA 降维后得到的各类主成分结合直接处理的指数平均收益投入 Ridge 模型中进行训练。利用验证集的参数来优化 Ridge 模型，进而对测试集进行合理的预测。因子动量择时进攻（FMTM）决策模型是在已经确定预测模型比较稳定的情况下，以最大化收益为优化函数，建立择时全仓进攻策略。该全仓策略不是一味的冒进，而是仅在综合进攻潜力为正且选定最优资产时才接近满仓出击，否则完全空仓，并且还有风险控制用于躲避亏损情况，设定阈值来防止模型频繁交易。与全仓持有基准相比，FMTM 在测试集上的最终收益普遍高于三种基准模型，并且在交易的过程中并没有出现过大的波动，体现出其合理性。

经分析，误差主要来源于：第一，训练数据有限（每段仅 100 天），预测模型难以精准捕捉未来走势，偶有方向误判；第二，决策模型为追求最大收益而采用全仓切换策略，牺牲了部分稳定性，在信号模糊时可能出现较大偏差。

由于决策模型对负收益单独做了监测，所以对亏损的发生相当敏感，灵敏度高，可以迅速调仓而防止资产受损。同时，模型对于进攻信号的侦察结合历史的数据进行评估，并采取大胆的全仓策略。尽管模型对瞬时市场变化的响应存在一定迟滞，但通过合理调参，其对趋势转变的捕捉仍保持在较灵敏的水平。

由于依托于较为准确的预测模型，和适配的大胆的全仓策略，决策的效果相当好，在三次回测中都明显优于三个基准模型。除此之外，模型的表现比较稳定，并没有出现剧烈性的暴涨或暴跌，只有少部分情况出现过轻微的异动，基本上全时间段稳定增长。相较于三个基准策略有明显的优势。预测模型对每日涨跌方向的判断基本准确，仅在具体涨跌幅度上存在一定偏差。

七、模型评价与改进

7.1 模型优点

7.1.1 严格的无未来信息时序框架

本模型在全流程中严格遵循‘无未来信息’原则：PCA 仅在训练集上拟合，Ridge 回归每次仅使用截至当日的历史数据，策略决策不依赖任何未来信号。滚动窗口回测是时间序列预测中避免前视偏差的标准方法，能够真实反映模型的样本外泛化能力[5]。PCA 变换矩阵仅由训练集数据估计得到，滚动 Ridge 回归在每一时点均仅拟合截至当日的样本，策略决策也仅依赖当日及之前的预测信号，完全符合量化投资的实盘测试规范。

7.1.2 高效的降维与特征重构

面对 SP100 与 HSI 合计 184 只成分股的高维收益率矩阵，模型采用主成分分析（PCA）将原始信息压缩为 5 个正交主因子，在保留成分股间协方差结构主要变异的同时大幅降低了噪声干扰[6]。在此基础上，进一步构造了因子动量（多周期滚动均值）、因子波动率（滚动标准差）以及截面离散度等衍生特征，显著丰富了输入特征的表达能力，为后续预测提供了多维度的市场状态信息。

7.1.3 稳健的回归预测与清晰的策略集成

预测层选用带有 L2 正则化的 Ridge 回归，通过网格搜索在验证集上选取最优正则化系数，有效抑制了高维特征下的过拟合风险[7]。决策层设计的“终极进攻策略”逻辑简明：综合模型预测收益率与近期实际动量计算综合进攻潜力，仅当潜力为正时才以接近满仓的比例配置于最优资产，否则空仓避险。该规则既保证了上涨行情中的充分参与，又在下行行情中通过空仓实现了净值保护，体现了主动择时的核心价值。

7.1.4 完善的评估体系与可视化输出

模型同时输出验证集与测试集的预测值、回归评价指标（MAE、相关系数）以及策略净值曲线，并与全仓 SP100、全仓 HSI、半仓 SP100+半仓 HSI 三种基准策略进行对比。策略评价中引入了年化收益率、年化波动率、夏普比率及最大回撤等风险调整后指标[8]。从输出的指标文件可知，预测模型对 SP100 和 HIS 的预测的皮尔逊系数分别为 0.72 和 0.81，说明了预测模型非常优良的预测能力。充分验证了模型的有效性与实战潜力。

7.2 模型缺点与改进方向

7.2.1 市场状态自适应能力不足

当前模型在全区间采用统一的 Ridge 回归预测器及固定的策略参数（如动量回看窗口、调仓阈值），未考虑市场在不同阶段（单边上涨、横盘震荡、急速下跌）中有效因子与数据分布的显著差异。例如，动量因子在趋势市中表现优异，而在震荡市中均值回复特征往往更为重要[9]。

改进方向：引入**市场状态识别模块**，实时计算滚动窗口内的趋势强度（累计收益率与波动率之比）与震荡程度（均线穿越次数或 Hurst 指数），将市场动态划分为“趋势上涨”、“趋势下跌”、“震荡”三种状态。针对每种状态训练独立的预测模型（如趋势市使用短期 LightGBM 侧重动量因子，震荡市使用 Huber 回归侧重反转因子），并在状态切换时平滑过渡。可借鉴隐马尔可夫模型（HMM）对市场状态进行概率推断，避免频繁切换带来的噪音干扰[10]。策略层面亦可联动调整：趋势市中提高目标仓位并放宽调仓阈值以充分捕捉行情，震荡市中则降低仓位、收紧阈值以减少无效交易。

7.2.2 策略风险控制维度较为单一

当前策略的风险管理仅依赖于“进攻潜力是否为正”的满仓/空仓切换，未对持仓过程中的回撤幅度和波动率变化进行主动干预。一旦模型判断失误，满仓持有

将承担全部下跌风险，导致净值曲线出现较大回撤。

改进方向：引入**波动率目标机制**，根据近期已实现波动率动态调整目标仓位，使策略在不同波动环境下保持相对稳定的风险暴露[11]。同时可设置**最大回撤止损纪律**，例如从阶段最高净值回撤超过预设阈值（如 8%）时强制降低仓位，待市场企稳后再恢复信号驱动。这两项措施能够在不改变预测逻辑的前提下显著平滑净值曲线、提升夏普比率，增强策略的稳健性。

7.2.3 决策规则可优化为连续权重分配

“满仓切换”的二元决策虽执行效率高，但在市场方向不够明朗时容易引发频繁换仓，既增加交易成本，也可能在趋势初期因阈值限制而踏空。

改进方向：将离散规则替换为**连续权重映射函数**。例如，将“综合进攻潜力”通过 Sigmoid 函数映射到 $[0, 0.98]$ 区间，使目标仓位随信号强度平滑变化。进一步地，可采用 **Black-Litterman 模型**将预测收益率作为主观观点融入资产配置框架，结合历史协方差矩阵生成更稳健的权重序列，从而降低换手率并提升风险调整后收益[12]。动态 Black-Litterman 方法还能将时变的条件分布纳入配置过程，进一步增强模型的适应性。

7.2.4 超参数选择依赖人工经验，未实现自动化优化

模型中的 PCA 因子数量、动量回看窗口、Ridge 正则化系数搜索范围、调仓阈值等关键超参数均基于人工设定或简单网格搜索，未能充分利用时序交叉验证进行系统化寻优。

改进方向：采用**时序交叉验证**在训练集上对关键超参数进行自动搜索，例如使用 TimeSeriesSplit 评估不同 PCA 因子数下验证集的预测表现，或利用 Optuna 等贝叶斯优化框架对策略参数进行联合调优[13]。此举可在保证无未来信息的前提下进一步提升模型的样本外泛化性能。

7.2.5 计算效率方面存在优化空间

滚动窗口下每一时点均需重新拟合 Ridge 回归，且涉及网格搜索，整体计算开销较大，不利于快速迭代实验与实盘部署。

改进方向：可采用**特征预计算 + 增量更新**策略。由于 PCA 因子和衍生特征可一次性生成完整矩阵，滚动训练仅需切片即可，无需重复构造特征。对于 Ridge 回归，可利用其解析解形式，在新增样本时通过 Woodbury 公式快速更新系数，大幅降低计算耗时[14]。

参考文献

- [1] 王翔, 胡学钢. 高维小样本分类问题中特征选择研究综述[J]. 计算机应用, 2017, 37(9): 2433-2438.
- [2] Lin C, Chang M, Sun Y. Assessing the efficacy of artificial intelligence in mitigating stock market volatility induced by emotional decision-making[C] // 2024 4th International Conference on Computer Communication and Artificial Intelligence (CCAI). 2024: 320-331.
- [3] Ishii R. Optimal execution in a market with small investors[J]. *Applied Mathematical Finance*, 2010, 17(5-6): 431-451.
- [4] CATTELL R B. The scree test for the number of factors[J]. *Multivariate Behavioral Research*, 1966, 1(2): 245-276.
- [5] Inoue A, Jin L, Rossi B. Rolling window selection for out-of-sample forecasting with time-varying parameters[J]. *Journal of Econometrics*, 2017, 196(1): 55-67.
- [6] Jolliffe I T, Cadima J. Principal component analysis: a review and recent developments[J]. *Philosophical Transactions of the Royal Society A*, 2016, 374(2065): 20150202.
- [7] Hoerl A E, Kennard R W. Ridge regression: Biased estimation for nonorthogonal problems[J]. *Technometrics*, 1970, 12(1): 55-67.
- [8] Sharpe W F. Mutual fund performance[J]. *The Journal of Business*, 1966, 39(1): 119-138.
- [9] Fama E F. Efficient capital markets: A review of theory and empirical work[J]. *The Journal of Finance*, 1970, 25(2): 383-417.
- [10] Spiteri L. Hidden Markov models and their extensions with applications in finance and gambling[D]. University of Malta, 2020.
- [11] Moskowitz T J, Ooi Y H, Pedersen L H. Time series momentum[J]. *Journal of Financial Economics*, 2012, 104(2): 228-250.
- [12] Black F, Litterman R. Asset allocation: combining investor views with market equilibrium[J]. *Goldman Sachs Fixed Income Research*, 1990.
- [13] Bergstra J, Bardenet R, Bengio Y, et al. Algorithms for hyper-parameter optimization[C]//*Advances in Neural Information Processing Systems*. 2011: 2546-2554.
- [14] Hastie T, Tibshirani R, Friedman J. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*[M]. 2nd ed. Springer, 2009.

附录

远程仓库:https://github.com/calcury/factor_momentum_tactical_model

```

├─ main.py      # 运行完整流水线
├─ requirements.txt  # 依赖项
├─ README.md
├─ config/
│   └─ prediction_model_config.json
├─ data/
│   ├── sp100.csv
│   ├── hsi.csv
│   └─ stock_static.csv  # Task1 生成的静态特征表
├─ result/      # 运行结果
│   ├── task1/
│   ├── task2/
│   └─ task3/
├─ src/
│   ├── task1/
│   │   ├── feature_analysis.py  # 特征分析与静态表生成
│   │   ├── correlation_coefficient.py  # 相关性分析
│   │   ├── cluster_kmeans.py  # K-means 聚类
│   │   └─ cluster_agglomerative.py  # 凝聚层次聚类
│   ├── task2/
│   │   ├── average_return.py  # 均值收益率分析
│   │   ├── variance_interpret.py  # PCA方差解释率计算
│   │   ├── prediction_model.py  # 滚动预测
│   │   └─ evaluate.py  # 皮尔逊相关系数分析
│   └─ task3/
│       ├── decision_model.py  # 基于预测结果的决策与回溯
│       └─ backtesting.py  # 完整回溯流程

```

```

# 日均收益率
daily_mean = returns.mean()
# 年化收益率
annual_return = daily_mean * TRADING_DAYS
# 年化波动率
daily_std = returns.std()
annual_volatility = daily_std * np.sqrt(TRADING_DAYS)
# 夏普比率
sharpe_ratio = (annual_return - RISK_FREE_RATE) / annual_volatility
# 累计收益率
cumulative_return = (1 + returns).prod() - 1
# 最大回撤
def max_drawdown(series):
    cum_values = (1 + series).cumprod()
    running_max = cum_values.cummax()
    drawdown = (cum_values - running_max) / running_max
    return drawdown.min()
max_dd = returns.apply(max_drawdown)
# 正收益天数占比
total_days = returns.shape[0]
win_rate = (returns > 0).sum() / total_days

```

统计指标计算

```


for i, date in enumerate(idx):
    nav = cash + sum(units.values())
    potentials = {}
    for asset, df in [(('sp100', df_sp), ('hsi', df_hsi))]:
        pred_r = df.at[date, 'pred_target_return']
        # 动能过滤
        start = max(0, i - self.momentum_lookback)
        mom = df['target_return'].iloc[start:i].sum()
        potentials[asset] = pred_r + \
            (mom * self.momentum_weight) # 预测 + 动能补偿

# 谁强买谁
best_asset = max(potentials, key=lambda x: potentials[x])


target_weights = {'sp100': 0.0, 'hsi': 0.0}
if potentials[best_asset] > 0:
    target_weights[best_asset] = self.target_exposure
else:
    # 两个都在跌, 空仓避险
    target_weights = {'sp100': 0.0, 'hsi': 0.0}

```

决策模型逻辑



相关性热力图



日均收益率